本勉強会で扱うプロジェクト

プロジェクトリンクを参照

使用場面

モデル・ロード・パターンでは推論サーバを配備する際、サーバイメージを Pull した後に推論サーバを起動し、その後にモデルファイルをロードして推論サーバを本稼働させます。モデルファイルのロード元を変数等で変更することによって、推論サーバで稼働するモデルを柔軟に変更することも可能です。

必須要件:

- Python 3.8 以上
- Docker
- Kubernetes クラスターまたは minikube

フォルダ構造

```
.dockerignore
  Dockerfile
  makefile
  README.md
  requirements.txt
  run.sh
  __init__.py
—manifests
      deployment.yml
      namespace.yml
⊢models
      default_iris_svc.onnx
      label.json
⊢model_loader
      Dockerfile
      main.py
      requirements.txt
      __init__.py
-src
      configurations.py
      constants.py
      __init__.py
    ⊢арр
         app.py
         __init__.py
```

```
routers
routers.py
__init__.py

hml
prediction.py
__init__.py

utils
logging.conf
profiler.py
__init__.py
```

Makefileの詳細(用意されたコマンド)

Makefileで指定されたコマンドについて解説

- make build_all
 - 推論用Docker イメージおよびモデルロード用Dockerイメージのビルド

注意:

- "Docker build"コマンドについて
 - 。 "-t" オプションでビルドするDockerのレポジトリを指定
 - "-f" オプションで使用するDockerfileを指定

step1

変数の定義は以下の通り

```
DOCKER_REPOSITORY := shibui/ml-system-in-actions

ABSOLUTE_PATH := $(shell pwd)

DOCKERFILE := Dockerfile

IMAGE_VERSION := 0.0.1

MODEL_LOAD_PATTERN := model_load_pattern

MODEL_LOAD_PATTERN_PORT := 8000

MODEL_LOADER := model_loader
```

step2

Docker Hub の"shibui/ml-system-in-actions"のレポジトリにある"model_loader_pattern_api"イメージ をビルド

参照リンク:DockerHub model_loader_pattern_api_0.0.1

```
.PHONY: build_api
build_api:
docker build \
```

```
-t $(DOCKER_REPOSITORY):\
$(MODEL_LOAD_PATTERN)_api_$(IMAGE_VERSION) \
-f $(DOCKERFILE) \
.
```

ここで使用するDockerfileはこちら

説明用資料.md

```
FROM python:3.8-slim
ENV PROJECT_DIR model_load_pattern
WORKDIR /${PROJECT_DIR}
ADD ./requirements.txt /${PROJECT_DIR}/
RUN apt-get -y update && \
    apt-get -y install apt-utils gcc && \
    apt-get clean && \
    rm -rf /var/lib/apt/lists/* && \
    pip install --no-cache-dir -r requirements.txt
COPY ./src/ /${PROJECT DIR}/src/
COPY ./models/label.json /${PROJECT_DIR}/models/label.json
ENV LABEL_FILEPATH /${PROJECT_DIR}/models/label.json
ENV LOG_LEVEL DEBUG
ENV LOG_FORMAT TEXT
COPY ./run.sh /${PROJECT_DIR}/run.sh
RUN chmod +x /${PROJECT_DIR}/run.sh
CMD [ "./run.sh" ]
```

基本的には、以下の点に注意:

- 使用されたコマンドの一覧
 - FROM:ベースとなるイメージ
 - ∘ ENV:環境変数の定義

"PROJECT_DIR"の変数に"model-load-pattern"をいれる。

- ADD:ファイルをDocker内に移動
- RUN: 実行
- o COPY: ディレクトリのコピー

step3

Docker Hub の"shibui/ml-system-in-actions"のレポジトリにある"model_loader_pattern_loader"イメージをビルド

参照リンク: DockerHub model_loader_pattern_loader_0.0.1

"-f"オプションで指定されているDockerfileがデフォルトのパスでないことに注意 ⇒同ディレクトリの"model_loader"フォルダ内のDockerfileを参照している。

```
.PHONY: build_loader
build_loader:
    docker build \
    -t $(DOCKER_REPOSITORY):\
    $(MODEL_LOAD_PATTERN)_loader_$(IMAGE_VERSION) \
    -f $(MODEL_LOADER)/$(DOCKERFILE) \
    .
```

ここで実行されるDockerfileはこちら

```
FROM python:3.8-slim

ENV PROJECT_DIR model_load_pattern
WORKDIR /${PROJECT_DIR}
COPY ./model_loader/requirements.txt /${PROJECT_DIR}/
COPY ./model_loader/main.py /${PROJECT_DIR}/src/main.py
RUN apt-get -y update && \
    apt-get -y install apt-utils gcc && \
    apt-get clean && \
    rm -rf /var/lib/apt/lists/* && \
    pip install --no-cache-dir -r requirements.txt && \
    touch src/__init__.py
```

step3

load_apiとbuild_loaderの実行

```
.PHONY: build_all
build_all: build_api build_loader
```

• make deploy

デプロイするコマンド."apply"コマンドでkubernetesで使用するpodを作成する。("Pod"についてはPodとはを参照のこと) 正確には、リソースの変更を反映し、前回実行時との差分を抽出する。

```
-f [Pod定義ファイル]:
```

Podを定義するyamlファイルを指定する。

```
.PHONY: deploy
deploy:
   kubectl apply -f manifests/namespace.yml
   kubectl apply -f manifests/deployment.yml
```

ここでは、"manifests"フォルダの"namespace.yml"、"deployment.yml"の変更の反映を実行している。
(Kubernetesの操作は"kubectl"で操作することできる。Kubernetesの操作については"Kubernetesの基本操作"を参照.)

各.yaml(いわゆるマニフェスト)ファイルには、kubernetesの処理を実行する内容が記載されている。

namespace.yml

名前空間を指定するマニフェスト内容:

```
apiVersion: v1
kind: Namespace
metadata:
name: model-load
```

• deployment.yml

デプロイ時に利用する"Pod"の作成を行う。ここでは、直接"Pod"を作成するのではなく、"Deployment"オブジェクトを生成することで"Pod"の一括生成を行っている。また、このファイルでは"Pod"の作成だけでなく、"service"オブジェクトによる、各Podへの管理を行っている。

"Service"は配下のPodへ通信を振り分けるもので、技術的にはプロキシやNATなどの仕組みを用いたロードバランサーに相当する。ワーカーノードが異なるにもかかわらず、1つのIPアドレスでアクセスできる。この機構はワーカーノード内のkube-proxyによって実現されている。

内容:

```
apiVersion: apps/v1
kind: Deployment
metadata:
  name: model-load
  namespace: model-load
  labels:
    app: model-load
spec:
  replicas: 4
  selector:
    matchLabels:
      app: model-load
  template:
    metadata:
      labels:
        app: model-load
    spec:
      containers:
        - name: model-load
          image: shibui/ml-system-in-actions:model_load_pattern_api_0.0.1
            - containerPort: 8000
          resources:
```

```
limits:
              cpu: 500m
              memory: "300Mi"
            requests:
              cpu: 500m
              memory: "300Mi"
          volumeMounts:
            - name: workdir
              mountPath: /workdir
          env:
            - name: MODEL_FILEPATH
              value: "/workdir/iris_svc.onnx"
      initContainers:
        - name: model-loader
          image: shibui/ml-system-in-actions:model_load_pattern_loader_0.0.1
          imagePullPolicy: Always
          command:
            - python
            - "-m"
            - "src.main"
            - "--gcs_bucket"
            - "ml_system_model_repository"
            - "--gcs_model_blob"
            - "iris_svc.onnx"
            - "--model_filepath"
            - "/workdir/iris_svc.onnx"
          volumeMounts:
            - name: workdir
              mountPath: /workdir
      volumes:
        - name: workdir
          emptyDir: {}
apiVersion: v1
kind: Service
metadata:
  name: model-load
  namespace: model-load
  labels:
    app: model-load
spec:
  ports:
    - name: rest
      port: 8000
      protocol: TCP
  selector:
    app: model-load
apiVersion: autoscaling/v2beta2
kind: HorizontalPodAutoscaler
metadata:
  name: model-load
```

```
namespace: model-load
 labels:
   app: model-load
spec:
 scaleTargetRef:
   apiVersion: apps/v1
    kind: Deployment
   name: model-load
 minReplicas: 3
 maxReplicas: 10
 metrics:
   - type: Resource
      resource:
        name: cpu
       target:
          type: Utilization
          averageUtilization: 50
```

kubectl -n model-load get pods,deploy,svc

ここでは、複数のコマンドが実行されていることに注意。

• コマンド1つ目

```
kubectl -n model-load get pods
```

ここでは、"model-load"と呼ばれる名前空間を指定し、その名前空間上で作られた"Pod"を確認するコマンド。

• コマンド2つ目

```
kubectl -n model-load get deploy
```

デプロイを確認するコマンド。

• コマンド3つ目

```
kubectl -n model-load get svc
```

サービス一覧を確認するコマンド

• make delete

.PHONY: delete

delete:

kubectl delete ns model-load

"model-load"の名前空間上に作成したオブジェクトをすべて破棄。

Kubernetesの基本操作

Kubernetesは基本的は"kubectl"で操作する。 基本的な構文は以下の通り。

kubectl [コマンド] [オプション]

マニフェストとは

kubectlでは、リソース(Kubernetesオブジェクト)を作成したり変更したりする操作をする一方、これらの設定値は数が多く、1つひとつkubectlの引数で設定すると、とても膨大になる。そこでリソースの情報は、ファイルとして記述しておき、それをkubectlに読み込ませるようにするのが一般的。リソースに関するデータを「マニフェスト(Manifest)」と呼び、それを記述したファイルを「マニフェストファイル」と呼ぶ。マニフェストファイルは、JSON形式もしくはYAML形式で記述する。JSON形式は、どちらというと機械的にやり取りすることを目的としたもので、人間がその設定ファイルを読み書きするのであれば、もっぱらYAML形式が使われる。

代表的なコマンド

コマンド	説明
create	リソースの作成
apply	リソースの変更を反映
delete	リソースの削除

Namespace

Kubu

単語集

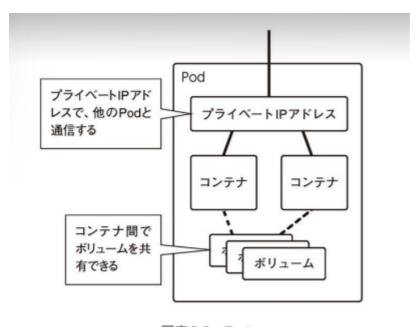
Podとは

Kubernetesにおける最小実行単位のこと。一つ以上の(基本一つ)コンテナ、いくつかのボリュームを含む。基本的な使い方としては、**最小単位の機能**を表現するものであるので、複数の処理を同時に同じpodに

含めるのは避ける必要がある。ボリュームはコンテナ間のデータ共有に使用が可能. また、POdには動的なプライベートIPアドレスが割り当てられ、含まれるコンテナはそのIPアドレスを共有することで他のPodと通信可能。

注意

- Pod内でのコンテナ同士がlocalhostで通信できる
- 含まれているコンテナ同士で競合するポート番号を利用できない



図表9-9 Pod

kubernetesとは

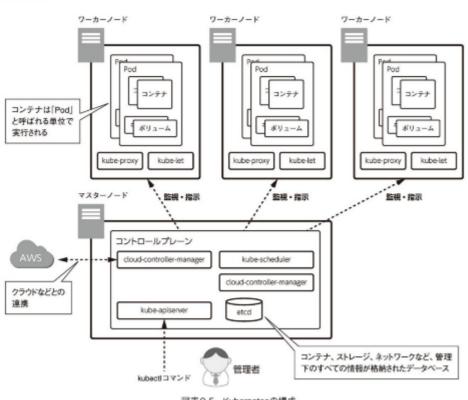
- Kubernetesを使うモチベーション
 - 。 冗長性
 - スケーラビリティ
- Kubernetesとは複数のコンテナ間をつなぐネットワークやストレージについて複数台のサーバーにまたがってコンテナを動かすプラットフォーム。基本的にはDockerコンテナの管理に使用されている。

システムを構成するサーバー群のことを"Kubernetes クラスター"と呼ぶ。クラスター を構成するサーバー群は役割によって「マスターノード」と「ワーカーノード」に分かれる。

• 役割

- マスターノードクラスター全体を統括管理するためのシステムをインストール下サーバー群。管理者はマスターノードを通じて指示出す。
- ワーカーノード ネットワークやストレージなどを構成し、実際にコンテナを動かすサーバー群。ワーカーノード内では個アンテナ、ネットワーク、ストレージを"Pod"単位で管理する。

2022/2/18 説明用資料.md



図表9-5 Kubernetesの構成

参考資料:

Kubenetesのコマンド集: https://qiita.com/suzukihi724/items/241f7241d297a2d4a55c

マニフェストへの記述: https://qiita.com/soymsk/items/69aeaa7945fe1f875822

Kubernetesの名前空間: https://qiita.com/jackchuka/items/a1456d8cab03651ddbf8

kubectl apply -f manifests/ https://qiita.com/tkusumi/items/0bf5417c865ef716b221